

Perancangan dan Analisis Sistem Adaptif Transmisi multi-path Protokol pada Jaringan Sensor Nirkabel Bawah Air untuk IKN smart city berbasis Algoritma Reinforcement Learning dan Klasterisasi k -Means

Muhamad Asvial ^{1*}, Annastya Bagas. Dewantara ¹

¹ Department of Electrical Engineering, Faculty of Engineering, Universitas Indonesia, Depok, Indonesia
Email: asvial@eng.ui.ac.id; annastya.bagas@ui.ac.id

*Corresponding author

Abstract— Noise, propagation loss dan propagation delay merupakan permasalahan utama pada Underwater Wireless Sensor Network. Dalam mengatasi permasalahan tersebut, penelitian ini dilakukan dengan menggunakan pendekatan multi layer trilateration pada proses deployment, multi agent reinforcement learning pada transmisi multi hop dan k -Means Clustering pada proses pemilihan cluster head, dengan mempertimbangkan energi residual dari Underwater Wireless Sensor Network. Analisis karakteristik perairan menggunakan studi kasus dari perairan laut Ibu Kota Nusantara dilakukan untuk mengetahui karakteristik channel Underwater Wireless Sensor Network sebelum melakukan pengujian performa dari protokol routing dan meningkatkan reabilitas simulasi dalam menirukan keadaan UWSN yang sebenarnya. Melalui penelitian ini di dapatkan frekuensi optimum dari perairan laut IKN pada kedalaman 1 km dan transmisi maksimum 500 m terletak pada frekuensi 38.51 kHz, dan daya transmisi minimum yang dibutuhkan untuk mendapatkan SNR sebesar 30 dB adalah 0.92 W. Melalui hasil penelitian yang di dapatkan, menunjukkan penggunaan multi layer trilateration mampu mengatasi redundansi serta meningkatkan coverage sensing pada Underwater Wireless Sensor Network. Pada pengujian routing protokol, klasterisasi menggunakan k -Means Clustering memiliki nilai energi disipasi rata-rata yang rendah pada setup phase dan mengungguli metode lainnya seperti DEKCS dan LEACH-K dengan nilai node failure yang rendah. Pada percobaan transmisi multi hop, pendekatan multi agent reinforcement learning mengungguli metode LEACH, LEACH-K, dan DEKCS pada total pengiriman data yang terkirim 113800 bytes.

Keywords—Underwater wireless sensor network, acoustic channel, LEACH, multi hop, k -Means, multi agent reinforcement learning, Ibu Kota Nusantara

I. INTRODUCTION

Pemindahan ibu kota negara Indonesia dari DKI Jakarta menuju Ibu Kota Nusantara (IKN) merupakan program pemerintah Indonesia dalam menciptakan pemerataan pembangunan sekaligus untuk mempercepat

transformasi ekonomi Indonesia. Dalam mencapai tujuan tersebut, perencanaan pembangunan infrastruktur dari IKN harus mempertimbangkan faktor-faktor sekuritas serta keselamatan masyarakat. IKN terletak pada persimpangan lempeng Indo-Australia, lempeng pasifik dan lempeng Eurasia, yang menyebabkan aktivitas pergeseran tektonik sering terjadi yang berpotensi terjadi bencana tsunami [1]. Salah satu tindakan preventif dari pencegahan tsunami adalah dengan menempatkan beberapa wireless sensor salah satunya sensor pressure akustik untuk memonitoring serta mendeteksi terjadinya aktivitas pergeseran tektonik yang digunakan sebagai system early warning tsunami [2], [3].

Kehadiran Wireless Sensor Network (WSN) telah merevolusi metode pengumpulan data serta proses monitoring data di dalam berbagai bidang meliputi industrial, automotive, military, agriculture, serta medical [4], [5], [6], [7], [8]. WSNs merupakan jaringan yang terdiri atas multiple small node yang memiliki kemampuan untuk melakukan sensing, komputasi serta komunikasi nirkabel satu sama lain ataupun ke base station (BS) melalui machine-to-machine protocol. Perkembangan teknologi manufaktur telah mendorong perkembangan teknologi sensor pada WSNs, salah satu dari penerapan tersebut adalah Internet of Underwater Things (IoUT) yang diterapkan melalui *floating buoy* atau *anchor buoy* untuk pengambilan data suhu, salinitas, tekanan, dan Cahaya [9], [10], [11]. Underwater Wireless Sensor Network merupakan arsitektur yang mengatur protocol transmisi dan penerimaan data dari IoUT. Permasalahan utama yang terjadi pada implementasi sistem UWSN adalah permasalahan atenuasi, interferensi, serta noise yang disebabkan oleh pengaruh lingkungan dan aktivitas manusia [12]. Protokol *routing* memainkan peranan penting dalam mengendalikan proses transmisi, agregasi serta integrasi data, yang berpengaruh pada reabilitas, latensi serta efisiensi energi dari UWSN. Selain itu, strategi *deployment* dari UWSN memiliki pengaruh terhadap skalabilitas serta *lifespan* dari UWSN[13].

Sehingga, desain protokol *routing* serta strategi *deployment* menjadi krusial dalam perancangan arsitektur UWSN untuk meningkatkan network lifetime, efisiensi penggunaan energi serta jumlah throughput yang dihasilkan dari sensor.

Terdapat beberapa pendekatan yang dapat dilakukan pada optimalisasi energy WSNs, Kamal dan Al-Karaki membagi jenis routing protocol berdasarkan network structure yakni flat, hierarchical dan location based protocol yang dapat dibagi kembali berdasarkan routing protocol yang diambil yakni multipath-based, query-based, negotiation based, quality of service (QoS) based dan coherent-based tergantung pada operational protocol yang digunakan [14]. Pada routing protocol network structure, system hierarchichal based protocol memiliki keunggulan dari flat dan location based protocol karena pada hierarchical based protocol terdapat the selection of node dimana sensing information is assigned to the nodes with low energy sedangkan data processing dan data transmisi di bebaskan pada node dengan energy tinggi, sehingga lifetime, scalability serta minimisasi energy dapat dicapai [15]. Liu membagi hierarchical based protocol ke dalam empat bagian yakni chain-based protocol, tree-based protocol, grid-based protocol, area-based protocol serta cluster-based protocol [16], dan menunjukkan keunggulan dari cluster-based protocol dalam hal scalability, load balancing serta network life.

Dalam mengatasi permasalahan *atenuasi*, *noise* dan limitasi energi beberapa pendekatan telah dilakukan, Rizvi et.al menggunakan pendekatan cluster-based protocol dengan menerapkan protocol LEACH, untuk menciptakan distribusi energy merata dengan membagi beban energy consumption yang sama pada setiap node [17], akan tetapi Pemilihan Cluster Head (CH) serta jumlah cluster pada LEACH di setiap rondonya didasarkan atas probabilitas random, yang menyebabkan system eleksi node untuk menjadi CH pada node dengan energy tinggi dan node dengan energy yang rendah memiliki probabilitas yang sama dan menyebabkan kehadiran orphan node karena letak CH yang jauh dari node, yang mana menjadi permasalahan pada LEACH. Terlebih lagi pada pengiriman data dari CH kepada BS masih didasarkan atas single hop, yang menjadikan penerapan LEACH tidak ideal pada large network [18].

Dalam mengatasi pemilihan CH random pada LEACH, Omeke et.al menerapkan system pemilihan CH yang di dasarkan atas algoritma *k*-Means dengan menggunakan parameter jarak antar Cluster serta threshold energy untuk node dapat terpilih sebagai CH, yang meningkatkan network balance dan load balance pada network [19], pendekatan serupa juga dilakukan oleh Krishnaswamy et.al, melalui pendekatan Fuzzy Logic pada LEACH untuk melakukan pemilihan CH dengan membagi node ke dalam beberapa level energy dan jarak antar cluster [20], akan tetapi pendekatan ini hanya menyelesaikan permasalahan yang terjadi pada setup phase, namun belum dapat menyelesaikan permasalahan orphan node serta transmisi single hop yang terlalu jauh pada proses Steady State.

Dalam mengatasi permasalahan yang terjadi pada transmisi single hop, Hu and Fei melakukan pendekatan transmisi multi hop menggunakan algoritma Q-Learning, untuk menurunkan energy yang terjadi pada proses Overhead serta menurunkan keberadaan node failure yang terjadi akibat orphan node. Pemilihan jalur multi hop dilakukan berdasarkan energy residual dari node asal hingga node tujuan [21], akan tetapi pendekatan menggunakan flat-based protocol memiliki skalabilitas yang rendah terutama pada network dengan area yang luas.

Strategi deployment dari UWSN memiliki pengaruh terhadap skalabilitas dan network lifetime dari UWSN, terutama pada implementasi yang membutuhkan resolusi pembacaan tinggi seperti aplikasi militer, tactical surveillance dan disaster prevention yang membutuhkan coverage serta jarak transmisi yang luas. Dalam mengatasi permasalahan tersebut, Pompli et.al mengajukan strategi trilateration untuk menentukan jumlah node optimum pada UWSN yang memperhitungkan coverage sensing serta jarak transmisi maksimum dari node [22]

Dalam mengatasi permasalahan *atenuasi*, *interferensi*, *noise* serta coverage yang terdapat pada UWSN, penelitian ini dilakukan dengan menerapkan konsep multi-layer trilateration untuk meningkatkan coverage sensing, konsep *k*-Means untuk memilih CH optimum serta multi agent Q-Learning untuk menciptakan route optimum pada setiap CH dan orphan node secara multi-hop untuk mengurangi jarak yang ditempuh dari CH ke BS maupun orphan node ke CH atau BTS. Penentuan CH serta route optimum akan didasarkan pada jarak serta energy residual dari masing-masing node terhubung untuk menciptakan load balancing pada UWSN. Evaluasi performa dari pendekatan ini akan dilakukan dengan membandingkan performa pada LEACH konvensional dengan pendekatan yang dilakukan, meliputi performa packet delivered, energy consumption serta network lifetime.

Penulisan dari paper ini dibagi ke dalam beberapa section, yakni : 1. Introduction, yang menjelaskan latar belakang, rumusan masalah, tujuan penelitian, ruang lingkup, dan sistematika penelitian; 2. Underwater Acoustic Channel Model, yang membahas terkait pemodelan dari lingkungan UWSN; 3 Proposed model, pada bagian ini menjelaskan langkah-langkah penelitian yang dilakukan yang terdiri dari pendekatan penelitian, persamaan yang digunakan, dan desain simulasi; 4. Methodology, bagian ini menjelaskan tentang alur penelitian, metode pengumpulan data dan pendekatan yang digunakan dalam menganalisis hasil data; 5. Result and Analysis This section describes the results and discussion of the simulations that have been carried out, which were evaluated on specific parameters; 6. Conclusion, this section contains findings drawn from the results and discussion, considering the research objectives and suggestions for research development.

II. UNDERWATER ACOUSTIC CHANNEL MODEL

Pemodelan dari karakteristik chanel akustik bawah air secara garis besar dipengaruhi oleh tiga komponen yakni propagation loss, propagation delay dan noise. Nilai

dari masing-masing komponen tersebut di pengaruhi oleh parameter-parameter seperti frekuensi operasi, jarak transmisi, kedalaman, salinitas, temperature serta pH pada lingkungan bawah air yang di dasarkan atas karakteristik dari lingkungan bawah air yang digunakan. Pemodelan dari karakteristik chanel akustik tersebut bertujuan untuk menghitung link budget serta mengetahui performa dari protocol UWSN yang digunakan.

Propagation loss merupakan besar loss yang dialami pada saat transmisi dari node satu ke node lainnya, loss tersebut disebabkan akibat absorbtion yang disebabkan oleh magnesium sulphate, boric acid, pergerakan partikel dan geometrical spreading. $A(d, f)$ merupakan propagation loss yang nilainya dipengaruhi oleh nilai jarak d , frekuensi f dengan satuan kilohertz, k koefisien spreading dan koefisien absorpsi $\alpha(f)$, yang ditunjukkan pada persamaan (1). Besar nilai k dipengaruhi oleh geometrical spreading untuk spherical ($k = 2$), untuk cylindrical ($k = 1.5$), dan untuk practical digunakan ($k = 1.5$) [12].

$$A(d, f) = d^k \alpha(f)^d \quad (1)$$

Pada pemodelan koefisien atenuasi, terdapat beberapa model yang digunakan, yakni Thorp, Fisher & Simons dan Ainslie & McColm. Persamaan Ainslie & McColm memiliki hasil yang akurat, karena menggunakan parameter kedalaman, temperature, salinitas dan pH dalam pemodelannya [23] Persamaan dari Ainslie & McColm ditunjukkan pada persamaan (2), dengan temperature dalam celcius T , salinitas dalam ppt S , f_1 dan f_2 adalah frekuensi relaksasi dengan satuan kilohertz, dan kedalaman D dengan satuan kilometer.

$$\begin{aligned} f_1 &= 0.78 \sqrt{\frac{S}{35}} e^{\frac{T}{26}} \\ f_2 &= 42 e^{\frac{T}{17}} \\ A_1 &= 0.106 \frac{f_1 f^2}{f_1^2 + f^2} e^{\frac{pH-S}{0.56}} \\ A_2 &= 0.52 \left(1 + \frac{T}{43} \right) \left(\frac{S}{35} \right) \frac{f_2 f^2}{f_2^2 + f^2} e^{\frac{-D}{0.56}} \\ A_3 &= 4.9 \times 10^{-4} f_2 \cdot e^{\frac{T}{27} + \frac{D}{17}} \\ \alpha(f) &= A_1 + A_2 + A_3 \end{aligned} \quad (2)$$

Komunikasi akustik nirkabel dipengaruhi oleh media yang dilalui, yang mana mempengaruhi throughput, latensi dan quality of service pada komunikasi data. Terdapat beberapa pemodelan yang digunakan untuk memodelkan kecepatan suara untuk propagasi bawah air, salah satunya adalah persamaan MacKenzie yang ditunjukkan pada persamaan (3), persamaan MacKenzie memiliki pemodelan yang lebih akurat ketimbang pemodelan lain seperti persamaan Medwin, pada pemodelan kedalaman lebih dari 1 km [24].

$$\begin{aligned} A_1 &= 1448.96 + 4.591 \cdot T - 5.304 \times 10^{-2} T^2 \\ A_2 &= 2.374 \cdot T^3 + 1.340 \cdot (S - 35) + 1.630 \times 10^{-2} \cdot D \\ A_3 &= 1.675 \times 10^{-7} D^2 - 1.025 \times 10^{-2} \cdot T \cdot (S - 35) \\ A_4 &= -7.139 \times 10^{-13} D^3 \cdot T \\ v_{uw} &= A_1 + A_2 + A_3 + A_4 \end{aligned} \quad (3)$$

Selain kecepatan suara, besar noise juga mempengaruhi quality of service dari komunikasi akustik. Ambient noise model merupakan model yang digunakan dalam merpresentasikan kehadiran noise pada bawah air, Ambient noise model dapat direpresentasikan ke dalam bentuk Gaussian dan memiliki continous power spectral density, dengan sumber noise terbesar adalah turbulensi N_T , aktivitas kapal N_S , ombak yang terbentuk akibat pergerakan angin N_W dan pengaruh termal N_{Th} [25], yang direpresentasikan pada persamaan (4).

$$\begin{aligned} N_T(f) &= 17 - 30 \log f \\ N_S(f) &= 40 + 20(s - 0.5) + 26 \log f - \\ &\quad 60 \log(f + 0.03) \\ N_W(f) &= 50 + 7.5 w^{\frac{1}{2}} + 20 \log f - 40 \log(f + 0.4) \\ N_{Th}(f) &= -15 + 20 \log f \\ N_{Total}(f) &= N_T(f) + N_S(f) + N_W(f) + N_{Th}(f) \end{aligned} \quad (4)$$

Dalam memperhitungkan besar transmisi daya serta QoS yang digunakan, perhitungan link budget dilakukan dengan mempertimbangkan signal-to-noise-ratio (SNR) yang nilainya dipengaruhi oleh atenuasi dan noise dengan jarak dan frekuensi sebagai variable dependant, yang ditunjukkan pada persamaan (5).

$$10 \log SNR(d, f) = 10 \log P_0 - 10 \log A(d, f) - 10 \log N_{Total}(f) \quad (5)$$

III. PROPOSE METHOD

Desain protokol routing serta strategi deployment memiliki peranan penting dalam menghadapi propagation loss, propagation delay serta noise merupakan pada implementasi UWSN. Dalam menghadapi permasalahan tersebut, penelitian ini menggunakan strategi deployment multi-layer trilateration dilakukan sebagai pengembangan dari trilateration oleh Pompili et.al [22], untuk meningkatkan coverage pembacaan serta mengurangi redundant node yang di deploy dengan memerhatikan jarak transmisi maksimum serta jarak sensing dari sensor yang ditunjukkan pada Fig 1. Pada desain protokol routing, penggunaan multi-hop LEACH dengan algoritma k -Means dan Q-learning digunakan untuk meningkatkan network lifetime, efisiensi penggunaan energi serta jumlah throughput yang dihasilkan oleh sensor.




Fig 1. Propose method architecture

LEACH merupakan hierarichal-based routing protocol yang membagi masing-masing node nya ke dalam bentuk structural ke dalam CH dan node member. LEACH juga dapat dikategorikan sebagai cluster-based routing protocol yang membagi jaringannya ke dalam bentuk cluster. Transmisi data dari LEACH menggunakan time-division-multiple-access (TDMA), karena pendekatan menggunakan TDMA menggunakan konsumsi energy yang rendah dengan menyimpan energy pada keadaan idle ketika channel sedang digunakan [26], Heinzelman et al. menjelaskan penggunaan TDMA bertujuan untuk menghindari terjadinya collision dan memudahkan pembagian bandwidth dengan fixed channelization scheme ketimbang FDMA yang memerlukan dynamic channelization scheme karena jumlah cluster yang tidak tentu di setiap rondanya. Pada pengoperasiannya pada tiap round, LEACH akan memiliki dua phase yakni set-up phase dan steady-state phase, yang ditunjukkan pada Fig 2.




Fig 2. LEACH operation time line

Pada protocol LEACH, node yang tidak memiliki data untuk dikirim akan mengalami idle pada periode waktu tertentu dan node yang memiliki data akan melakukan penerimaan dan pengiriman data ke CH/BS. Persamaan yang digunakan pada pemodelan UWSN menggunakan model modifikasi dari Rizvi et.al [27], dengan mengubah dari bentuk energi ke dalam bentuk daya serta menghapus unsur energi disipasi dari pengaruh energi elektronik pada persamaan karena nilai nya yang jauh lebih kecil ketimbang energy transmit, idle dan receive. Modifikasi persamaan tersebut menyerupai persamaan Li dan Lazarou [28], dengan penambahan disipasi energi pada pembentukan cluster.

Daya yang dibutuhkan pada saat pengiriman data dari node member ke CH serta dari CH ke BS di representasikan sebagai P_{tx} pada persamaan (6), yang dipengaruhi oleh propagation loss pada persamaan (1). Sebaliknya daya yang dibutuhkan untuk menerima data di representasikan dengan P_{rx} . Daya idle P_{idle} merupakan

energy disipasi ketika node tidak melakukan pengiriman data.

$$P_{tx}(d) = P_0 \cdot A(d, f) \quad (6)$$

Bernoulli trial digunakan untuk memodelkan event pengiriman data dari node yang ditunjukkan pada persamaan (7) dengan probabilitas dari node memiliki data untuk dikirim adalah p , banyak trial n dalam hal ini adalah jumlah node, dan nilai expected value $E(X)$ merupakan perkiraan jumlah node yang dapat melakukan pengiriman data [28]

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \text{ for } k = 0, \dots, n \quad (7)$$

$$E(X) = np$$

Besar throughput dari UWSN dipengaruhi oleh medium propagasi yang mempengaruhi kecepatan propagasi. Pada WSN terrestrial kecepatan propagasi dari pengiriman data adalah kecepatan cahaya sehingga ratio delay (ζ) antara waktu transmisi $\tau_{transmission}$ dan waktu propagasi $\tau_{propagation}$ mendekati nol. Ketiga komponen tersebut di tunjukkan pada persamaan (8)-(10). Pada TDMA nilai $\tau_{transmission}$ dipengaruhi oleh control packet k_c , data packet k_d , dan k_{total} dalam bytes dan μ adalah bitrate dengan satuan bit/s. Pada UWSN, kecepatan propagasi sensor akustik dipengaruhi oleh medium bawah air yang ditunjukkan pada persamaan (3), yang menyebabkan ratio delay pada UWSN signifikan lebih besar ketimbang WSN terrestrial.

$$\tau_{transmission} = \frac{k_c + k_d + k_t}{\mu} \quad (8)$$

$$\tau_{propagation} = \frac{d}{v_{uw}} \quad (9)$$

$$\zeta = \frac{\tau_{transmission}}{\tau_{propagation}} \quad (10)$$

Pada pemilihan cluster head, LEACH menggunakan non-persistent carrier-sense-multiple-access-collision-avoidance (CSMA/CA). Non-persistent CSMA memiliki throughput lebih besar ketimbang 1-persistent CSMA dan p-persistent CSMA karena non-persistent CSMA menggunakan teknik random backoff untuk mengecek apakah channel busy berdasarkan periode waktu random [29]. Persamaan throughput dari Non-persistent di representasikan oleh ρ dan ditunjukkan pada persamaan (11).

$$\rho = \frac{k_c \cdot e^{-\zeta \cdot k_c}}{k_c (1 + 2\zeta) + e^{-\zeta \cdot k_c}} \quad (11)$$

Pada setup phase proses pemilihan CH, dilakukan berdasarkan probabilitas random pada setiap rondanya,

yang dapat menyebabkan permasalahan, salah satunya adalah jarak node member dengan CH yang terlalu jauh. Hal ini menyebabkan node tidak dapat melakukan pengiriman data dan menjadi orphan node, serta node failure yang terjadi akibat energy node habis ketika melakukan pengiriman.

Dalam mengatasi permasalahan tersebut, penelitian ini dilakukan dengan menggunakan algoritma k -Means clustering pada menentukan pemilihan CH. Jarak transmisi memiliki peranan penting pada proses disipasi energi. Semakin besar jarak antar CH dengan member node, semakin besar juga energi yang digunakan pada proses pengiriman data. Pada penelitian ini penentuan CH di dasarkan atas parameter koordinat lokasi serta energi residual dari node.

$$\bar{X}_i = [x_i \quad y_i \quad z_i]^T \quad (12)$$

Dalam menentukan kluster, algoritma k -Means menggunakan fungsi objektif untuk meminimalkan euclidian distance dari centroid μ_j dengan terhadap vektor node i -th \bar{X}_i dari banyak sensor N dan banyak kluster K , yang di tunjukkan pada persamaan (12), dengan fungsi objektif ditunjukkan pada persamaan (13). Algoritma k -Means clustering memperbarui posisi centroid pada setiap iterasinya. Proses update dari posisi centroid di dasarkan atas derivasi parsial, dengan posisi centroid setelah di update berubah terhadap derivasi parsial dari fungsi objektif yang ditunjukkan pada persamaan (14).

$$J = \min_{\mu_j} \sum_{i=0}^{N-1} \sum_{j=0}^{K-1} r_{nk} \left\| \bar{X}_i - \mu_j \right\|_2^2 \quad (13)$$

$$r_{nk} = \begin{cases} 1, & \text{if } k = \arg \min_j \left\| \bar{X}_i - \mu_j \right\|_2^2 \\ 0, & \text{Otherwise} \end{cases}$$

Tahapan pemilihan CH dan pembentukan kluster, tidak hanya dilakukan pada optimasi teknik pemilihan kluster, namun juga dengan menambahkan perhitungan jumlah kluster optimum. Penelitian terkait penentuan jumlah kluster optimum telah banyak dilakukan, Zytoune et.al melakukan perhitungan kluster berdasarkan area, banyak node serta jarak ke base station [30], Hamaali et.al menggunakan elbow method dalam menentukan kluster optimum berdasarkan nilai sum of squared dari jarak node terhadap nilai centroidnya [31]. Akan tetapi, terdapat limitasi pada kedua pendekatan tersebut, yakni perhitungan optimum kluster hanya di dasarkan atas koordinat lokasi dari node. Penelitian ini menggunakan Shiloutte method dengan mempertimbangkan energi residual dari node dalam menghitung optimum kluster sebelum melakukan proses pemilihan CH.

$$\frac{\partial}{\partial \mu_j} \sum_{i=0}^{N-1} \sum_{j=0}^{K-1} r_{nk} \left\| \bar{X}_i - \mu_j \right\|_2^2 = 0 \quad (14)$$

$$\mu_j = \frac{\sum_{i=0}^{N-1} r_{nk} \bar{X}_i}{\sum_{i=0}^{N-1} r_{nk}}$$

Proses penunjukkan node sebagai CH, dilakukan berdasarkan nilai λ tertinggi. Nilai λ merepresentasikan score pemilihan CH dari jarak euclidian dari node satu dengan node lainnya pada satu kluster serta energi residual dari masing-masing node yang ditunjukkan pada persamaan (7). Dalam proses perhitungan λ , transformasi data dilakukan melalui standardisasi dilakukan untuk menyamakan skala dari lokasi koordinat dengan energi.

$$\lambda = \arg \min_{\bar{X}_i} \sum_{i=0}^{N-1} \sum_{j=0}^{K-1} r_{nk} \left(\left\| \bar{X}_i - \bar{X}_j \right\|_2^2 + \frac{1}{E_i} \right) \quad (15)$$

Pada proses pemilihan CH, node yang terpilih untuk menjadi CH akan mengirimkan control packet ke base station untuk menginformasikan status pengangkatannya sebagai CH, node yang memiliki data untuk dikirim akan mengalami idle yang dimodelkan melalui bernoulli trial pada persamaan (9). Setelah control packet diterima oleh base station, base station akan mengirimkan control packet kembali kepada CH yang berisikan schedule pengiriman data dari masing-masing kluster. Ketiga tahapan tersebut di representasikan pada persamaan (16) sebagai pemodelan disipasi energi pada proses seleksi.

$$E_{selection} = \frac{T_c}{\rho} P_{tx} (d_{CH-BS}) + \frac{(p \cdot N - 1) T_c}{\rho} P_{idle} + T_t P_{rx} \quad (16)$$

Masing-masing dari CH akan membroadcast advertisement message menggunakan non persistent CSMA dari media-access-control (MAC) protocol yang ditunjukkan pada persamaan (19). Setiap node menentukan daerah cluster nya masing-masing berdasarkan received energy strength dari CH yang ditunjukkan pada persamaan (20), dengan mengirimkan join-request message ke CH.

$$E_{adv} = T_c \cdot P_{tx} (d_{max}) \quad (19)$$

$$E_{join} = p \cdot N \cdot T_c \cdot P_{rx} \quad (20)$$

Pada steady state phase, setiap CH membentuk TDMA schedule dan melakukan broadcast dari schedule tersebut ke seluruh node pada clusternya N_c , sebagai konfigurasi dari data transmisi yang ditunjukkan pada persamaan (21). Masing-masing dari node akan menerima schedule yang diterima dari broadcast CH, kemudian mengirimkan packet control kepada CH dan mengalami fase idle yang ditunjukkan pada persamaan (22).

Masing-masing dari node akan mengirimkan data packet kepada CH kedalam bentuk frame m untuk dialokasikan ke dalam slot transmisi dengan durasi frame pada tiap member node adalah konstan yang ditunjukkan pada persamaan (23). Data packet tersebut diterima dan di agregasi oleh CH untuk kemudian dikirimkan ke base station ditunjukkan pada persamaan (24) menggunakan transmisi single hop.

$$E_{frame-node} = m \cdot T_d \cdot P_{tx} (d_{node-CH}) \quad (23)$$

$$E_{frame-CH} = m \cdot N_c \cdot P_{rx} \cdot T_d + m(N - N_c)P_{idle}T_d + P_{tx}(d_{CH-BS}) \cdot T_d \quad (24)$$

Penggunaan transmisi single hop seringkali menyebabkan terjadinya node failure. Salah satu penyebab terjadinya node failure adalah jarak pengiriman data dari node terhadap CH melebihi jarak transmisi maksimum, yang menyebabkan node tidak dapat melakukan pengiriman data dan menjadi node orphan. Dalam mengatasi permasalahan tersebut, penelitian ini melakukan pendekatan transmisi multi hop dengan reinforcement learning untuk menciptakan rute optimum sebagai jalur transmisi data.

Reinforcement learning (RL) adalah salah satu pendekatan dalam machine learning di mana sebuah agen belajar bagaimana mengambil tindakan dalam sebuah lingkungan untuk mencapai tujuan tertentu [32]. Algoritma RL di dasarkan atas Markov Decision Process (MDP) yang dikarakteristikan oleh kehadiran empat parameter yakni (S, A, P, R) , dimana S adalah set of states, A set of actions, P set of transition probabilitas dan R adalah set of rewards.

Pada MDP, komponen P terdiri atas $P_{s,s'}^a$, yang merepresentasikan probabilitas transisi dari state s menuju state selanjutnya s' dengan mengambil aksi a . Probabilitas dari perpindahan state terhadap state ditunjukkan pada persamaan (25), dengan total dari probabilitas bernilai satu, dengan $a \in A(s)$ dan $s \in S$.

$$P_{s,s'}^a = \Pr \left\{ s_{t+1} = s' \mid s_t = s, a_t = a \right\} \quad (25)$$

$$\sum_{s' \in S} P_{s,s'}^a = 1$$

Perpindahan yang dilakukan oleh agent state s ke state selanjutnya s' pada aksi a dan waktu t akan memperoleh direct reward r_t yang ditunjukkan pada persamaan (26). Persamaan tersebut merepresentasikan akumulasi dari immediate reward $R_{s_t, s_{t+1}}^{a_t}$ yang didapatkan oleh agent dalam melakukan aksi pada seluruh possible next state.

$$r_t = r(s, a) \Big|_{s_t=s, a_t=a} \quad (26)$$

$$= \sum_{s_{t+1} \in S} P_{s_t, s_{t+1}}^{a_t} R_{s_t, s_{t+1}}^{a_t}$$

$$E_{sch-CH} = N_c P_{rx} T_c + P_{tx} (d_{max}) T_c \quad (21)$$

$$E_{sch-node} = \frac{T_c}{\rho} P_{tx} (d_{CH-node}) + \frac{(N_c - 1) T_c}{\rho} P_{idle} + T_t P_{rx} \quad (22)$$

Transisi dari state s ke state selanjutnya s' ditentukan oleh aksi a , yang menyebabkan pengambilan keputusan atas aksi yang dilakukan memiliki peranan penting dalam mencapai tujuan. Penggunaan policy π digunakan dalam menentukan aksi terbaik pada suatu state ke dalam bentuk probabilitas yang di dasarkan atas expected reward E_π [33], yang ditunjukkan pada persamaan (27).

$$E_\pi \{r_t\} = E_\pi \{r(s_t, a_t)\} \quad (27)$$

$$= \sum_{a_t \in A} \pi(s_t, a_t) r_t$$

Nilai dari state s pada policy π sebagai expected total reward sebagai value function di representasikan dengan $V^\pi(s)$ yang ditunjukkan pada persamaan (28). Value dari $V^\pi(s)$ dipengaruhi oleh discount factor γ . Nilai γ berada pada interval $[0, 1)$, nilai γ yang rendah akan membuat pengaruh current reward lebih signifikan dari future reward, akan tetapi hal ini dapat menyebabkan model cenderung konvergen ke local optimum dan bukan global optimum, sebaliknya nilai γ yang tinggi akan menyebabkan model sensitif dan slower learning [34], dengan nilai k merepresentasikan index dari future step.

$$V^\pi(s) = E_\pi \left\{ R_t \mid s_t = s \right\} \quad (28)$$

$$= E_\pi \left\{ \sum_{k=0}^{\infty} \gamma^k r_{t+k} \mid s_t = s \right\}$$

Tujuan dari reinforcement learning adalah mendapatkan nilai state optimum. Nilai state optimum di dapatkan dengan memaksimalkan nilai $V^\pi(s)$. Nilai dari $V^\pi(s)$ dipengaruhi oleh policy dalam pengambilan aksi. Maka untuk mendapatkan $V^*(s)$, pengambilan aksi harus di dasarkan atas nilai maksimum dari reward yang di dapatkan yang disebut sebagai bellman equation [32].

$$V^*(s) = \max_{\pi} V^\pi(s) \quad (29)$$

$$= \max_{\pi} E_\pi \left\{ \sum_{k=0}^{\infty} \gamma^k r_{t+k} \mid s_t = s \right\}$$

Secara teori nilai dari policy optimum dapat diselesaikan menggunakan persamaan (29), akan tetapi pendekatan ini membutuhkan waktu yang cukup lama untuk konvergen, membutuhkan komputasi besar dalam pemrosesannya serta membutuhkan pengetahuan terhadap

environment seperti transition probabilities atau reward dari model [35], yang mana hal ini sulit dilakukan pada wireless sensor communication karena lingkungan dari network yang dinamik dan unpredictable serta resource seperti energi yang terbatas.

Dalam mengatasi permasalahan tersebut, pendekatan model free dengan Q-learning digunakan untuk mengetahui policy optimum dari aksi a pada state s yang di representasikan pada persamaan (30), ketimbang mengevaluasi seluruh policy pada state s seperti persamaan (29) yang membutuhkan komputasi besar.

$$Q^\pi(s, a) = E_\pi \left\{ R_t \middle| s_t = s, a_t = a \right\} \quad (30)$$

$$= E_\pi \left\{ r_t + \sum_{k=1}^{\infty} \gamma^k r_{t+k} \middle| s_t = s, a_t = a \right\}$$

Sama halnya seperti $V^*(s)$, tujuan akhir dari Q-learning adalah untuk mendapatkan policy optimum dari $Q^\pi(s, a)$ sebagai Q function. Namun, perbedaan antara $V^*(s)$ dengan $Q^*(s, a)$ adalah pada $Q^*(s, a)$ pengambilan strategi optimum bertujuan untuk mendapatkan aksi yang dapat memaksimalkan nilai $Q^\pi(s, a)$ di tunjukkan pada persamaan (31).

$$Q^*(s, a) = \max_{\pi} Q^\pi(s, a) \quad (31)$$

Penentuan policy optimum dari $Q^*(s, a)$ membutuhkan iterasi berulang terhadap seluruh state dan seluruh aksi serta membutuhkan informasi terhadap transition probabilities dari lingkungan. Dalam mengatasi permasalahan tersebut, pendekatan temporal difference dilakukan untuk mengestimasi nilai $Q^\pi(s, a)$ melalui proses iterasi untuk mengupdate nilai dari $Q(s, a)$. Pada temporal difference, agent berinteraksi dengan lingkungannya pada setiap time step secara sequential untuk mengupdate nilainya berdasarkan nilai immediate dan future reward sepanjang waktu yang ditunjukkan pada persamaan (32).

$$\delta e(s_t, a_t) = r_t + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t) \quad (32)$$

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \delta e(s_t, a_t)$$

Pengambilan aksi untuk mendapatkan policy optimum pada reinforcement learning seringkali dihadapkan permasalahan exploration dan exploitation. Exploration merupakan pengambilan aksi baru untuk mendapatkan informasi dari lingkungan, menurunkan tingkat uncertainty dan mencegah model untuk konvergen di local optima. Exploitation merupakan pengambilan aksi optimum yang didasarkan atas pengetahuan model, eksploitasi yang terlalu berlebihan dapat menyebabkan model mengalami konvergen prematur pada local optima. Dalam menyeimbangkan permasalahan exploration dan exploitation, penggunaan algoritma ϵ -greedy digunakan pada persamaan (32) dengan mentuning nilai ϵ untuk mendapatkan policy optimum [36].

Pemodelan lingkungan UWSN dari Q-learning bertujuan untuk menciptakan transmisi multi hop untuk pengiriman data dari orphan node ke base station. Pemodelan diawali melalui pembentukan graph G dengan masing-masing vertex merepresentasikan node serta edge E yang menghubungkan vertex V , merepresentasikan relasi antar vertex. Node tersebut di representasikan ke dalam bentuk s state $s \in S$, dengan nilai $S = \{s_1, s_2, \dots, s_N\}$. Graph tersebut membentuk adjacency matrix yang digunakan sebagai immediate reward pada persamaan (34). Adjacency matrix sebagai graph memudahkan interpretasi dalam memahami relasi serta karakteristik dari jaringan [37]. Nilai edge yang menghubungkan vertex, disusun menggunakan weighted edge yang didasarkan atas energi residual serta jarak terhadap node pada state selanjutnya yang ditunjukkan pada persamaan (33), yang bertujuan untuk meningkatkan efisiensi energi dari network [38].

$$w_{m,n} = E_n + \frac{1}{\|\bar{X}_n - \bar{X}_m\|_2^2} \quad (33)$$

$$r(s, a) = \begin{matrix} & s_1 & s_2 & s_3 & \dots & s_m \\ \begin{matrix} a_1 \\ a_2 \\ a_3 \\ \vdots \\ a_n \end{matrix} & \begin{bmatrix} w_{1,1} & \dots & \dots & \dots & w_{m,1} \\ \vdots & \ddots & & & \vdots \\ \vdots & & \ddots & & \vdots \\ \vdots & & & \ddots & \vdots \\ w_{1,n} & \dots & \dots & \dots & w_{m,n} \end{bmatrix} \end{matrix} \quad (34)$$

Proses multi hop dilakukan melalui sensor satu ke sensor lainnya hingga mencapai base station. Dalam melakukan transisi dari state satu ke state lainnya, agent harus melakukan aksi, pengambilan aksi berbeda-beda pada setiap state $a \in A(s)$. Ilustrasi proses pengiriman data ditunjukkan pada Fig 3., ditunjukkan proses pengiriman data dari sensor ke-1 yang di representasikan pada s_1 . Ilustrasi tersebut menunjukkan pengiriman data dari state s_1 ke base station melalui pengambilan aksi awal dari tiga aksi berbeda $A(s_1) = \{a_1, a_2, a_3\}$. Perpindahan state s_1 ke state s_2 dilakukan berdasarkan pengambilan aksi dari possible aksi pada state s_1 berdasarkan policy optimum dari $Q(s, a)$ yang di update berdasarkan immediate reward $R_{s_t, s_{t+1}}^{a_t}$.




Fig 3. State transition

Pada fase steady state, terdapat beberapa orphan node yang tidak memiliki CH untuk dikirimkan data, sehingga node orphan tersebut harus mengirimkan data secara multi hop ke base station. Masing-masing sensor tersebut bergerak sebagai agent dan mengirimkan data dengan mengupdate graph tersebut secara dinamik dan sequential yang ditunjukkan pada Algorithm 1., yang dikenal sebagai Sequential multi agent reinforcement learning [39].

Algorithm 1 Multihop Transmission Pseudocode	
Input	: $\alpha, \gamma, \epsilon, O \in S, Q(s, a)$
Output	: $Q^*(s, a)$
For each $O \in S$ do:	
	$G(E, V) \leftarrow$ Create a graph and reward function
	$s \leftarrow$ State of the orphan node
	For each episode do:
	While not base station do:
	$n \leftarrow$ uniform random $[0,1]$
	If $n < \epsilon$ Then:
	$a' = \max Q(s, a)$
	Else:
	$a' = \text{random } a \in A(s)$
	End
	$s \leftarrow s'$
	$a \leftarrow a'$
	$Q(s, a) \leftarrow Q(s, a) + \alpha \delta e(s, a)$
	End For
End For	

IV. METHODOLOGY

Penelitian ini bertujuan untuk merancang desain protokol routing adaptif serta sensor deployment efisien melalui tiga pendekatan utama, yaitu Multi-agent reinforcement learning pada transmisi multi-hop untuk node orphan, k -Means algorithm pada pemilihan CH dengan fungsi objektif yang dimodifikasi serta multi layer trilateration dalam menurunkan redundansi dan meningkatkan coverage sensing. Analisis serta pemodelan matematis dari underwater akustik channel di perairan laut IKN untuk memberikan informasi serta pemahaman tambahan yang berguna pada penerapan implementasi UWSN terhadap karakteristik lingkungan tersebut.

Penelitian ini menggunakan pendekatan kuantitatif melalui analisis numerik dan statistik terhadap hasil dari simulasi dan komparasi. Metode sampling dilakukan secara eksperimental berbasis simulasi program komputer melalui pemodelan lingkungan bawah air laut IKN yang didasarkan atas parameter-parameter yang ditunjukkan pada Table 1, studi literatur serta hasil analisis yang dilakukan. Analisis performa dari pendekatan dilakukan melalui proses iterative sampling dengan melakukan komparasi dari pendekatan yang dilakukan dengan pendekatan yang telah dilakukan sebelumnya. Komparasi metode deployment dilakukan dengan melakukan perbandingan coverage sensing dari multi layer trilateration dengan random distribution. Kemudian, pada

desain routing protokol, komparasi dilakukan dengan membandingkan pendekatan yang dilakukan dengan pendekatan DEKCS oleh Omeke et.al [19] dan k -Means oleh Gantassi et.al [40]. Evaluasi performa didasarkan atas beberapa metrik, yakni network lifetime, total packet delivered, dan energi konsumsi, untuk mengetahui kelebihan dan limitasi pada metode yang diajukan.

TABLE I. SIMULATION PARAMETERS

Parameters	Values
Depth	1000 m
Length	1000 m
Width	1000 m
Sensing range	250 m
Transmission range	500 m
Spreading factor (k)	1.5
Number of frames (m)	10
Control packet (k_c)	25 bytes
Data packet (k_d)	250 bytes
Initial energy	500 J
Bernoulli probability	0.95
p	0.1

Dalam memperoleh karakteristik lingkungan UWSN pada perairan IKN, studi literatur dan analisis dilakukan untuk memperoleh nilai salinitas, pH, temperatur dan kecepatan angin serta aktivitas kapal yang merupakan parameter penentu dalam menentukan karakteristik lingkungan UWSN yang merupakan variable dependant pada persamaan (1)-(5). Selain karakteristik perairan IKN, Analisis terhadap penentuan nilai frekuensi optimum, daya transmisi minimum serta protokol pengiriman juga dilakukan pada penelitian ini sebelum melakukan pengujian performa dari protokol routing dan untuk meningkatkan reabilitas simulasi dalam menirukan keadaan UWSN yang sebenarnya. Penentuan frekuensi optimum di dapatkan melalui analisis nilai propagation loss serta noise dengan memvariasikan kedalaman dari peletakkan sensor. Sedangkan penentuan daya yang dibutuhkan, dilakukan melalui analisis link budget pada nilai SNR yang diinginkan. Pada analisis throughput, variasi dari protokol dilakukan untuk mengetahui performa dari protokol tersebut pada lingkungan UWSN sebagai data pendukung terhadap pendekatan yang dilakukan.

Dalam menciptakan desain protokol routing adaptif, proses tuning hyperparameter dari parameter ϵ -greedy serta nilai α dilakukan untuk menentukan parameter optimum pada algoritma multihop multi agent reinforcement learning. Proses tuning hyperparameter tersebut dilakukan dengan memvariasikan nilai ϵ dan α pada interval (0,1) dengan $\Delta\epsilon$ dan $\Delta\alpha$ bernilai 0.1 dan nilai γ adalah 0.5 terhadap nilai energi konsumsi minimum pada transmisi multi hop untuk mendapatkan nilai parameter ϵ dan α pada global minima dari nilai energi

konsumsi yang digunakan pada pengambilan data dan komparasi metode.

V. RESULT AND DISCUSSION

Informasi karakteristik perairan laut IKN tersebut bertujuan untuk mengetahui model dari underwater akustik channel. Laut IKN terletak pada daerah selat makassar. Pada kedalaman 1 km, laut IKN memiliki karakteristik dari salinitas, pH dan temperatur sebesar 34.31 ppt, 7.82 dan 4.11°C [41], [42]. Selat makassar dipengaruhi oleh angin southeast monsoon yang menyebabkan fenomena upwelling dengan kecepatan angin 6 m/s [43]. Pembangunan IKN bertujuan untuk menggantikan perkembangan ekonomi dari Jakarta. Hal ini memicu terjadinya peningkatan aktivitas kapal dari aktivitas pengiriman logistik ataupun perdagangan [44]. Atas dasar tersebut, penentuan konstanta aktivitas kapal yang diperlukan pada persamaan (4) di asumsikan bernilai 0.8.




Fig 4. Karakteristik Noise Underwater Akustik Channel Laut IKN

Noise merupakan komponen penentu kualitas sinyal yang diterima. Distribusi noise pada perairan laut IKN dalam pemodelan underwater akustik channel dilakukan menggunakan persamaan (4) dengan parameter karakteristik perairan IKN di dapatkan bahwa pengaruh turbulensi memiliki pengaruh tinggi pada frekuensi 0-10 Hz. Pada frekuensi 10-100 Hz, aktivitas kapal memiliki pengaruh tinggi. Pada frekuensi 100 Hz - 100 kHz pengaruh dari kecepatan angin memiliki pengaruh tinggi, dan di atas frekuensi 100 kHz, thermal memiliki pengaruh tinggi yang ditunjukkan pada Fig 4.

Frekuensi dapat dikatakan sebagai frekuensi optimum, apabila memiliki terletak pada nilai SNR minimum. Persamaan (5) menunjukkan relasi antara SNR dengan atenuasi dan noise, semakin besar nilai atenuasi dan noise maka akan semakin kecil nilai dari SNR. Nilai atenuasi dan noise bergantung pada variabel jarak serta frekuensi yang diberikan. Ditunjukkan pada Fig 5 dengan memvariasikan jarak yang berbeda-beda, di dapatkan frekuensi optimum berbeda-beda pada setiap jaraknya. Pada penelitian ini, peletakkan sensor diletakkan di daerah kedalaman 1 km dan di dapatkan frekuensi optimum pada nilai 38.51 kHz.




Fig 5. Pengaruh frekuensi terhadap noise dan atenuasi

Perhitungan link budget dilakukan untuk mendapatkan daya minimum nilai P_0 dalam mencapai nilai SNR 30 dB. Melalui perhitungan pada kedalaman D sebesar 1 km, dan frekuensi optimum f_{opt} sebesar 38.51 kHz, di dapatkan nilai noise total sebesar 23.94 dB dan nilai atenuasi sebesar -54.27 dB, dengan nilai P_0 sebesar 0.32 dB atau 0.92 W. Hasil dari perhitungan tersebut akan digunakan sebagai dasar dalam menentukan daya transmit, daya receive serta daya idle dari sensor akustik.




Fig 6. Pengaruh frekuensi terhadap noise dan atenuasi

Propagasi delay pada underwater akustik channel mempengaruhi nilai throughput. Persamaan (11) dan (12) menunjukkan pengaruh ratio delay yang nilainya dipengaruhi oleh kecepatan propagasi. Kecepatan propagasi akustik di underwater pada kedalaman 1 m bernilai sebesar 1630.85 m/s dan pada kedalaman 1 km bernilai sebesar 1630.87 m/s. Pada Fig 6, ditunjukkan perbedaan antara throughput pada kecepatan propagasi underwater dengan kecepatan propagasi pada kecepatan cahaya pada bitrate sebesar 500 bit/s. Gambar tersebut menunjukkan nilai throughput terbesar terdapat pada protokol Non-persistent CSMA, hal ini disebabkan pada Non-persistent CSMA, pengiriman data oleh sensor, dilakukan dengan menunggu CH/BS dalam keadaan idle, apabila CH/BS sedang sibuk maka sensor tersebut akan menunggu waktu backoff random sebelum mengirimkan data kembali. Hal ini akan mengurangi potensi terjadinya collision yang disebabkan akibat banyan sensor yang mengirimkan data secara bersamaan, hasil penelitian tersebut selaras dengan penelitian Zhao et.al yang

menunjukkan performa protokol CSMA yang baik pada underwater [45].

Melalui perhitungan analisis theoritical diketahui daya minimum P_0 yang dibutuhkan untuk mengirimkan data pada jarak 1 km dan SNR 30 dB adalah 0.92 W. Maka daya dari sensor yang digunakan harus melebihi nilai P_0 . Dalam pengujian performa protokol, nilai P_0 , P_{rx} , P_{idle} yang digunakan adalah 2 W, 0.5 W dan 2 mW, penentuan nilai tersebut dilakukan secara arbitrary berdasarkan nilai yang umum digunakan pada modem akustik komersial [46].

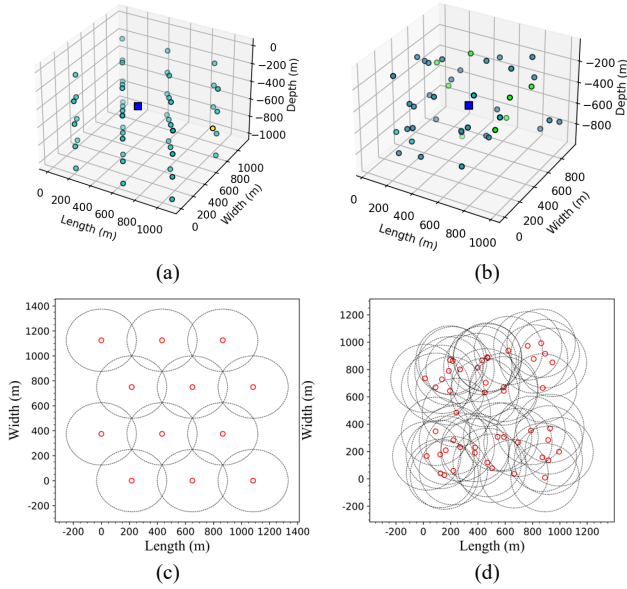


Fig 7. Deployment Comparison

(a) Multi-layer Trilateration deployment in 3D view (b) Random deployment in 3D view (c) Multi-layer Trilateration deployment in 2D view (d) Random deployment in 2D view

Penelitian ini menggunakan multilayer trilateration pada proses deployment yang ditunjukkan pada Fig 7(a). Penempatan dari masing-masing sensor pada metode deployment dilakukan dengan menghitung jarak serta coverage sensing dari masing-masing sensor dengan tujuan mencegah terjadinya redundansi, meningkatkan skalabilitas dan reabilitas yang biasa terjadi pada proses deployment terdistribusi random yang ditunjukkan pada Fig 7(b). Redundansi pada distribusi random tersebut terjadi akibat coverage sensing yang saling overlapping yang ditunjukkan pada Fig 7 (c) dan (d), dengan lingkaran merah merepresentasikan lokasi sensor dan lingkaran hitam putus-putus merepresentasikan area coverage sensor pada xy-axis.

Variasi parameter ϵ dan α pada proses tuning hyperparameter bertujuan untuk mendapatkan parameter optimum pada transmisi multi hop dari algoritma multi agent reinforcement learning. Transmisi multi hop optimum dapat dilakukan apabila model mendorong masing-masing node orphan untuk melakukan pengiriman data. Hal ini dapat dicapai dengan memasukkan parameter dari koordinat global maxima dimana energi residual terendah dari UWSN terletak yang ditunjukkan pada Fig 8.

Melalui variasi tersebut, di dapatkan nilai transmisi multi hop optimum pada lokasi global maxima dari energi residual pada parameter nilai α sebesar 0.204 dan nilai ϵ sebesar 0.312.




Fig 8. Tuning hyperparameter multi agent reinforcement learning

Pengujian protokol routing dilakukan menggunakan parameter yang telah di tetapkan serta parameter yang di dapatkan melalui hasil analisis. Protokol routing di awali melalui proses pembentukan cluster pada fase setup menggunakan pendekatan modified k -Means. Pengujian performa terhadap metode modified k -Means dilakukan dan ditunjukkan pada Fig 9 bahwa disipasi energi rata-rata dari pendekatan tersebut mengungguli pendekatan DEKCS dan LEACH-K, dengan rata-rata disipasi energi dari pendekatan yang di ajukan sebesar 7.15 J, sedangkan untuk DEKCS 17.28 J, LEACH-K sebesar 7.98 J dan LEACH sebesar 3.84 J.




Fig 9. Energy dissipation during the setup phase

Nilai energi disipasi pada setup fase yang rendah pada LEACH disebabkan akibat proses pemilihan CH yang gagal. Proses pemilihan CH pada LEACH di dasarkan atas probabilitas random dan nilai threshold, hal ini menyebabkan terjadinya situasi dimana tidak adanya CH yang terpilih pada round tertentu. Hal ini membuat masing-masing dari node mengalami fase idle pada

periode waktu tersebut, yang mengakibatkan nilai energi disipasi setup yang rendah. Pada pendekatan DEKCS, proses pemilihan CH di dasarkan atas jarak minimum antar node dalam kluster serta energi threshold dari nilai yang di tetapkan. Pada pemilihan energy threshold 3 J, kandidat dari node yang memenuhi syarat untuk menjadi CH semakin terbatas menyebabkan jarak transmisi dari CH terhadap member nodenya semakin jauh serta menyebabkan nilai node failure yang besar yang ditunjukkan pada Fig 10. Pada metode protokol routing yang di ajukan, node orphan yang tidak masuk ke dalam kluster manapun akan melakukan pengiriman transmisi multi hop. Node orphan tersebut akan mencari jalur optimum untuk mengirimkan data ke base station, apabila node orphan tersebut tidak menemukan jalur optimum maka node tersebut akan mengalami proses idle dan mengalami node failure.




Fig 10. Komparasi node failure pada variasi pendekatan yang diberikan

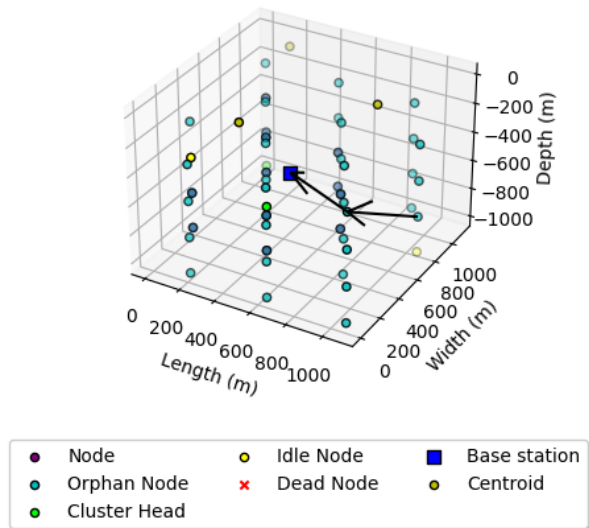


Fig 11. Transmisi multi hop dari node orphan

Peristiwa node orphan terjadi pada fase setup. Pada metode LEACH konvensional, node orphan terjadi akibat jarak dari CH yang terlalu jauh, menyebabkan node tidak memiliki CH untuk mengirimkan data dan terjadi

node failure. Multi agent reinforcement learning bertujuan untuk menciptakan jalur optimum untuk node orphan agar dapat mengirimkan datanya melalui relay node di sekitarnya hingga terkirim ke base station yang ditunjukkan pada Fig 11.

Ditunjukkan pada Fig 12, melalui pendekatan multi hop transmission menyebabkan meningkatnya jumlah data yang diterima oleh base station. Total data yang diterima menggunakan pendekatan tersebut mengungguli metode lainnya dengan total data yang dikirim 113800 bytes, sedangkan metode lainnya seperti LEACH-K sebesar 74800 bytes, LEACH sebesar 63000 bytes dan DEKCS sebesar 43900 bytes.

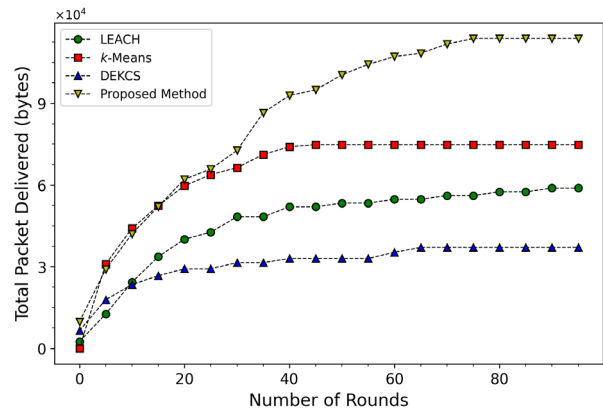


Fig 12. Total packet delivered pada variasi pendekatan yang diberikan

Fase pengiriman data menuju BS terjadi pada fase steady. Pada metode yang diajukan, terlihat pada Fig 13 mengalami disipasi energi yang lebih besar dan lebih lama dari pendekatan lainnya. Hal yang mengakibatkan disipasi energi dari pendekatan lainnya berlangsung lebih cepat dan lebih kecil disebabkan akibat ketiadaan CH pada periode tersebut yang memaksa untuk node mengalami proses idle dan terjadi node failure.




Fig 13. Energy dissipation during the steady phase

Jarak dari transmisi multi hop bergantung pada relay node di sekitarnya. Semakin banyak pilihan node di sekitarnya, maka semakin banyak pilihan jalur yang dapat dipilih dan semakin pendek jalur transmisi hop yang perlu ditempuh. Hal ini menyebabkan disipasi energi pada pendekatan yang diajukan mengalami perbedaan pada ronde awal dan ronde akhir. Pendekatan DEKCS

memprioritaskan network lifetime sebagai parameter utamanya yang ditunjukkan pada Fig 14 dan Fig 15, bahwa pendekatan DEKCS memiliki keunggulan dari pendekatan-pendekatan lainnya.

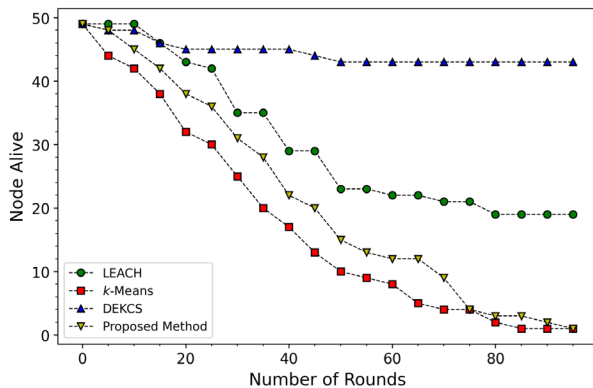


Fig 14. Network lifetime pada variasi pendekatan yang diberikan




Fig 15. Energi residual pada variasi pendekatan yang diberikan

VI. CONCLUSION

Melalui penelitian yang dilakukan, di dapatkan frekuensi optimum dari perairan laut IKN pada kedalaman 1 km dan transmisi maksimum 500 m terletak pada frekuensi 38.51 kHz, dan daya transmisi minimum yang dibutuhkan untuk mendapatkan SNR sebesar 30 dB adalah 0.92 W. Melalui hasil penelitian yang di dapatkan, menunjukkan penggunaan multi layer trilateration mampu mengatasi redundansi serta meningkatkan coverage sensing pada Underwater Wireless Sensor Network. Pada pengujian routing protokol, klasterisasi menggunakan *k*-Means Clustering memiliki nilai energi disipasi rata-rata yang rendah pada setup phase dan mengungguli metode lainnya seperti DEKCS dan LEACH-K dengan nilai node failure yang rendah. Pada percobaan transmisi multi hop, pendekatan multi agent reinforcement learning mengungguli metode LEACH, LEACH-K, dan DEKCS pada total pengiriman data yang terkirim 113800 bytes. In future works, pendekatan deep reinforcement learning perlu dilakukan untuk menggabungkan pendekatan multi agent reinforcement learning dengan deep learning untuk meningkatkan ke akuratan pembentukan jalur transmisi multi hop dan meningkatkan energi UWSN.

CONFLICT OF INTEREST

Please declare whether or not the submitted work was carried out with a conflict of interest. If yes, please state any personal, professional or financial relationships that could potentially be construed as a conflict of interest. If no, please add "The authors declare no conflict of interest".

FUNDING

Please add funding information here, e.g., this research was funded by NAME OF FUNDER, grant number XX. If there is no funding, this section can be removed.

REFERENCES

- [1] H. Sri Naryanto Peneliti Ahli Utama pada Pusat Teknologi Reduksi Risiko Bencana, K. TPSA -Badan Pengkajian dan Penerapan Teknologi Gedung BPPT, J. M. Thamrin, G. Geostech, K. Puspipitek Serpong, and T. Selatan, "Analisis Sumber Tsunami untuk Pertimbangan Perencanaan Jalur Kabel InaCBT di Selat Makassar," *Jurnal ALAMI : Jurnal Teknologi Reduksi Risiko Bencana*, vol. 5, no. 1, pp. 8–18, Jul. 2021, doi: 10.29122/ALAMI.V5I1.4736.
- [2] M. Inoue, Y. Tanioka, and Y. Yamanaka, "Method for Near-Real Time Estimation of Tsunami Sources Using Ocean Bottom Pressure Sensor Network (S-Net)," *Geosciences 2019, Vol. 9, Page 310*, vol. 9, no. 7, p. 310, Jul. 2019, doi: 10.3390/GEOSCIENCES9070310.
- [3] K. Casey, A. Lim, and G. Dozier, "A Sensor Network Architecture for Tsunami Detection and Response," *Int J Distrib Sens Netw*, vol. 4, pp. 27–42, 2008, doi: 10.1080/15501320701774675.
- [4] J. Yick, B. Mukherjee, and D. Ghosal, "Wireless sensor network survey," *Computer Networks*, vol. 52, no. 12, pp. 2292–2330, Aug. 2008, doi: 10.1016/J.COMNET.2008.04.002.
- [5] G. Cui *et al.*, "Detecting Rain-Snow-Transition Elevations in Mountain Basins Using Wireless Sensor Networks," *J Hydrometeorol*, vol. 21, no. 9, pp. 2061–2081, Sep. 2020, doi: 10.1175/JHM-D-20-0028.1.
- [6] P. Sanjeevi, S. Prasanna, B. Siva Kumar, G. Gunasekaran, I. Alagiri, and R. Vijay Anand, "Precision agriculture and farming using Internet of Things based on wireless sensor network," *Transactions on Emerging Telecommunications Technologies*, vol. 31, no. 12, p. e3978, Dec. 2020, doi: 10.1002/ETT.3978.
- [7] P. Barsocchi *et al.*, "Wireless Sensor Networks for Continuous Structural Health Monitoring of Historic Masonry Towers," *International Journal of Architectural Heritage*, vol. 15, no. 1, pp. 22–44, Jan. 2021, doi: 10.1080/15583058.2020.1719229.
- [8] H. Askari, A. Khajepour, M. B. Khamesee, and Z. L. Wang, "Embedded self-powered sensing systems for smart vehicles and intelligent transportation," *Nano Energy*, vol. 66, p. 104103, Dec. 2019, doi: 10.1016/J.NANOEN.2019.104103.
- [9] J. Trevathan *et al.*, "SEMAT — The Next Generation of Inexpensive Marine Environmental Monitoring and Measurement Systems," *Sensors 2012, Vol. 12, Pages 9711-9748*, vol. 12, no. 7, pp. 9711–9748, Jul. 2012, doi: 10.3390/S120709711.
- [10] C. A. Pérez, M. Jimenez, F. Soto, R. Torres, J. A. López, and A. Iborra, "A system for monitoring marine environments based on wireless sensor networks," *OCEANS 2011 IEEE - Spain*, 2011, doi: 10.1109/OCEANS-SPAIN.2011.6003584.
- [11] E. Felemban, "Acoustic frequency optimization for underwater wireless sensor network," *International Journal of Advanced Computer Science and Applications*, vol. 11, no. 6, pp. 642–648, 2020, doi: 10.14569/IJACSA.2020.0110678.
- [12] D. Bradley, "Handbook of Underwater Acoustic Engineering," *J Acoust Soc Am*, vol. 120, no. 5, pp. 2393–2393, Nov. 2006, doi: 10.1121/1.2354068.
- [13] D. Zeng, X. Wu, Y. Wang, H. Chen, K. Liang, and L. Shu, "A Survey on Sensor Deployment in Underwater Sensor Networks," *Communications in Computer and Information*

- Science, vol. 418 CCIS, pp. 133–143, 2014, doi: 10.1007/978-3-642-54522-1_14/COVER.
- [14] J. N. Al-Karaki and A. E. Kamal, "Routing techniques in wireless sensor networks: A survey," *IEEE Wirel Commun*, vol. 11, no. 6, pp. 6–27, Dec. 2004, doi: 10.1109/MWC.2004.1368893.
- [15] M. Haque, T. Ahmad, and M. Imran, "Review of Hierarchical Routing Protocols for Wireless Sensor Networks," *Lecture Notes in Networks and Systems*, vol. 19, pp. 237–246, 2018, doi: 10.1007/978-981-10-5523-2_22/COVER.
- [16] X. Liu, "Atypical Hierarchical Routing Protocols for Wireless Sensor Networks: A Review," *IEEE Sens J*, vol. 15, no. 10, pp. 5372–5383, Oct. 2015, doi: 10.1109/JSEN.2015.2445796.
- [17] H. H. Rizvi, S. A. Khan, and R. N. Enam, "Clustering Base Energy Efficient Mechanism for an Underwater Wireless Sensor Network," *Wirel Pers Commun*, vol. 124, no. 4, pp. 3725–3741, Jun. 2022, doi: 10.1007/S11277-022-09536-X/FIGURES/5.
- [18] I. Daanoun, B. Abdennaceur, and A. Ballouk, "A comprehensive survey on LEACH-based clustering routing protocols in Wireless Sensor Networks," *Ad Hoc Networks*, vol. 114, p. 102409, Apr. 2021, doi: 10.1016/J.ADHOC.2020.102409.
- [19] K. G. Omeke *et al.*, "DEKCS: A Dynamic Clustering Protocol to Prolong Underwater Sensor Networks," *IEEE Sens J*, vol. 21, no. 7, pp. 9457–9464, Apr. 2021, doi: 10.1109/JSEN.2021.3054943.
- [20] V. Krishnaswamy, S. Kumar, and S. Manvi, "Clustering and data aggregation scheme in underwater wireless acoustic sensor network," *TELKOMNIKA (Telecommunication Computing Electronics and Control)*, vol. 17, no. 4, pp. 1604–1614, Aug. 2019, doi: 10.12928/TELKOMNIKA.v17i4.11379.
- [21] T. Hu and Y. Fei, "QELAR: A Machine-Learning-Based Adaptive Routing Protocol for Energy-Efficient and Lifetime-Extended Underwater Sensor Networks," *IEEE Trans Mob Comput*, vol. 9, no. 6, pp. 796–809, Jun. 2010, doi: 10.1109/TMC.2010.28.
- [22] D. Pompili, T. Melodia, and I. F. Akyildiz, "Three-dimensional and two-dimensional deployment analysis for underwater acoustic sensor networks," *Ad Hoc Networks*, vol. 7, no. 4, pp. 778–790, Jun. 2009, doi: 10.1016/J.ADHOC.2008.07.010.
- [23] S. Aydin and T. O. Onur, "Investigation of parameters affecting underwater communication channel," *Journal of Engineering Sciences*, vol. 7, no. 1, pp. 39–44, 2020, doi: 10.21272/jes.2020.7(1).f4.
- [24] H. Medwin, "Speed of sound in water: A simple equation for realistic parameters," *J Acoust Soc Am*, vol. 58, no. 6, pp. 1318–1319, Dec. 1975, doi: 10.1121/1.380790.
- [25] R. F. W. Coates, "Underwater Acoustic Systems," *Underwater Acoustic Systems*, 1990, doi: 10.1007/978-1-349-20508-0.
- [26] L. P. Clare, G. J. Pottie, and J. R. Agre, "Self-organizing distributed sensor networks," *Unattended Ground Sensor Technologies and Applications*, vol. 3713, p. 229, Jul. 1999, doi: 10.1117/12.357138.
- [27] H. H. Rizvi, S. A. Khan, R. N. Enam, M. Naseem, K. Nisar, and D. B. Rawat, "Adaptive Energy Efficient Circular Spinning Protocol for Dynamic Cluster Based UWSNs," *IEEE Access*, vol. 10, pp. 61937–61950, 2022, doi: 10.1109/ACCESS.2022.3181589.
- [28] J. Li and G. Y. Lazarou, "A bit-map-assisted energy-efficient MAC scheme for wireless sensor networks," *Third International Symposium on Information Processing in Sensor Networks, IPSN 2004*, pp. 55–60, 2004, doi: 10.1145/984622.984631.
- [29] G. Y. Lazarou, J. Li, and J. Picone, "A cluster-based power-efficient MAC scheme for event-driven sensing applications," *Ad Hoc Networks*, vol. 5, no. 7, pp. 1017–1030, Sep. 2007, doi: 10.1016/J.ADHOC.2006.05.001.
- [30] O. Zytoune, D. Aboutajdine, and M. Tazi, "Energy balanced clustering algorithm for routing in heterogeneous wireless sensor networks," *2010 5th International Symposium on I/V Communications and Mobile Networks, ISIVC 2010*, 2010, doi: 10.1109/ISVC.2010.5656182.
- [31] G. W. Hamaali, K. A. Abduljabbar, and D. R. Sulaiman, "K-means Clustering and PSO Algorithm for Wireless Sensor Networks Optimization", doi: 10.31663/tqjues.13.1.475(2023).
- [32] L. Adaptation and A. Optimization, "Reinforcement Learning State-of-the-Art," vol. 12.
- [33] H. Yu and D. P. Bertsekas, "Q-learning and policy iteration algorithms for stochastic shortest path problems," *Ann Oper Res*, vol. 208, no. 1, pp. 95–132, Sep. 2013, doi: 10.1007/S10479-012-1128-Z/METRICS.
- [34] X. Lin, Q. Xing, and F. Liu, "Choice of discount rate in reinforcement learning with long-delay rewards," *Journal of Systems Engineering and Electronics*, vol. 33, no. 2, pp. 381–392, Apr. 2022, doi: 10.23919/JSEE.2022.000040.
- [35] M. Van Otterlo and M. Wiering, "Reinforcement learning and markov decision processes," *Adaptation, Learning, and Optimization*, vol. 12, pp. 3–42, 2012, doi: 10.1007/978-3-642-27645-3_1/COVER.
- [36] V. Bulut, "Optimal path planning method based on epsilon-greedy Q-learning algorithm," *Journal of the Brazilian Society of Mechanical Sciences and Engineering*, vol. 44, no. 3, pp. 1–14, Mar. 2022, doi: 10.1007/S40430-022-03399-W/FIGURES/17.
- [37] J. Cota-Ruiz, P. Rivas-Perea, E. Sifuentes, and R. Gonzalez-Landaeta, "A Recursive Shortest Path Routing Algorithm with Application for Wireless Sensor Network Localization," *IEEE Sens J*, vol. 16, no. 11, pp. 4631–4637, Jun. 2016, doi: 10.1109/JSEN.2016.2543680.
- [38] Z. A. Dagdeviren, "Weighted Connected Vertex Cover Based Energy-Efficient Link Monitoring for Wireless Sensor Networks towards Secure Internet of Things," *IEEE Access*, vol. 9, pp. 10107–10119, 2021, doi: 10.1109/ACCESS.2021.3050930.
- [39] Y. S. Nasir and D. Guo, "Multi-Agent Deep Reinforcement Learning for Dynamic Power Allocation in Wireless Networks," *IEEE Journal on Selected Areas in Communications*, vol. 37, no. 10, pp. 2239–2250, Oct. 2019, doi: 10.1109/JSAC.2019.2933973.
- [40] R. Gantassi, B. Ben Gouissem, and J. Ben Othmen, "Routing Protocol LEACH-K Using K-Means Algorithm in Wireless Sensor Network," *Advances in Intelligent Systems and Computing*, vol. 1150 AISC, pp. 299–309, 2020, doi: 10.1007/978-3-030-44038-1_27/COVER.
- [41] W. S. Pranowo *et al.*, "Characteristic of Temperature and Salinity in The Makassar Strait Based on Arlindo 2005 and Timit 2015 CTD Cruise Data," *Jurnal Chart Datum*, vol. 8, no. 2, pp. 107–116, Nov. 2022, doi: 10.37875/CHARTDATUM.V8I2.144.
- [42] H. Mahasiswa, O. " Triton," Institut, T. Bandung, P. Sains, and T. Kelautan, "PROSIDING SEMINAR NASIONAL KELAUTAN," 2012, Accessed: Jan. 30, 2024. [Online]. Available: <http://www.fitb.itb.ac.id/kk-oseanografi>
- [43] F. G. Utama, A. S. Atmadipoera, M. Purba, E. H. Sudjono, and R. Zuraida, "Analysis of upwelling event in Southern Makassar Strait," *IOP Conf Ser Earth Environ Sci*, vol. 54, no. 1, p. 012085, Jan. 2017, doi: 10.1088/1755-1315/54/1/012085.
- [44] L. Aprianti, M. A. Berawi, S. Gunawan, and M. Sari, "CONCEPTUAL DESIGN OF PORT DEVELOPMENT TO SUPPORT THE LOGISTICS SUPPLY OF INDONESIA'S NEW NUSANTARA CAPITAL CITY," pp. 367–379, 2023, doi: 10.31705/WCS.2023.31.
- [45] Q. Zhao, A. J. Lambert, and C. R. Benson, "A note on CSMA performance in underwater acoustic networks," *Comput Commun*, vol. 55, pp. 62–68, Jan. 2015, doi: 10.1016/J.COMCOM.2014.08.016.
- [46] S. Sendra, J. Lloret, J. M. Jimenez, and L. Parra, "Underwater Acoustic Modems," *IEEE Sens J*, vol. 16, no. 11, pp. 4063–4071, Jun. 2016, doi: 10.1109/JSEN.2015.2434890.